

2022 민족사관고등학교 DEFCON

학술 연구회 연구 논문

이미지 업 스케일링 기법과
이미지의 특성에 따른 보간 성능 평가

지도교사 김 창 환

2022년 10월

민족사관고등학교

DEFCON

학술 연구회 연구 논문

한 준 희, 김 진 호

목 차

제 1 장 서론	1
1.1 연구배경	1
1.2 연구목적	2
제 2 장 업 스케일링 기법의 종류 및 특성	3
2.1 업 스케일링이란?	3
2.2 Nearest Neighbor Interpolation 의 원리와 특성	3
2.3 Linear Interpolation 의 원리와 특성	4
2.4 Bicubic Interpolation 의 원리와 특성	6
2.5 Lanczos Interpolation 의 원리와 특성	7
제 3 장 이미지 업 스케일링 성능 평가 척도	8
3.1 이미지의 여러가지 수치	8
3.2 PSNR 수치의 특성과 계산법	8
3.3 SSIM 수치의 특성과 계산법	9
3.4 기타 수치들의 특성과 계산법	9
제 4 장 이미지 업 스케일링 성능 평가를 위한 실험 설정	10
4.1 실험의 변인 설정	10
4.2 실험 방식 설정	10
제 5 장 이미지 업 스케일링 성능 평가	11
5.1 성능 평가 데이터	11
5.2 결과 요인 분석	11
제 6 장 결론 및 고찰	13
제 7 장 참고 문헌	15

제 1 장 서론

1.1 연구 배경

이미지 업 스케일링 기법은 저 화질이거나 손상된 이미지를 복구하고 화질을 향상시키기 위해 널리 연구, 개발되어 왔다. 이를 이용한 SaaS (Software as a Service) 들도 많이 개발되어 있는데, 이 프로그램들은 주로 하나의 기법만을 이용해 이미지 업 스케일링을 진행한다. 하지만, 본 연구자들은 이미지 업 스케일링 과정에서 이미지의 특성에 따라 기법 별 업 스케일링 성능 수치가 크게 다르다는 점을 파악하였다. 기존의 방식대로 여러가지 종류의 이미지에 대해 한가지의 업 스케일링 기법을 적용하게 된다면, 일부 이미지들에 대해 높은 복원률을 기록하지 못하는 경우가 생기게 된다. 본 연구는 이러한 문제점을 해결하기 위해 이미지 종류에 따른 최적의 보간법을 찾고자 하였다.

1.2 연구 목적

선행 연구에서 확인하였듯, 현재 개발되어 사용되고 있는 이미지 업 스케일링 기법들의 종류는 매우 다양한데, 수학적 기법을 이용해 단순 연산을 사용하는 업 스케일링 기법들부터, 인공지능 학습을 통한 AI 이미지 업 스케일링 기법들까지 다양한 기법들이 개발되어 있다. 하지만, 기존의 업 스케일링 기법들은 모두 장단점을 가지고 있다. 예로, waifu2x 라는 이름의 이미지 업 스케일링 AI가 있다. waifu2x 이미지 업

스케일링 AI는 컨볼루션 신경망을 기반으로 하며, NVIDIA CUDA를 이용해 작동되는 AI이다. waifu2x 는 ‘애니메이션 스타일’의 그림에 특화되어 있는 설계와 성능을 보이는데, 개발팀에서 제공하는 통계에 의하면, 애니메이션 스타일 이미지들에 대해 98%가 넘는 복원률을 기록한다. 하지만, 일반적인 풍경화나 인물 사진들에 대해서는 매우 약한 성능을 보이는데, 이는 AI의 신경망이 특정 형태의 이미지들에 익숙하게 학습되어 있기 때문으로 판단 가능하다.

이렇듯 AI 이미지 업 스케일링 기법들의 경우, 여러 유형의 이미지들에 대해 모두 균등한 업 스케일링 성능을 보이기 보다는, 특정 유형의 이미지에 높은 성능을 보이고, 다른 유형들에 대해서는 좋지 못한 성능을 보이는 경우가 대부분임을 다양한 AI 업 스케일러들에 대한 분석을 통해 확인하였다.

이에, 본 연구자들은 전통적 방식의 이미지 업 스케일링 기법들에 대한 이미지 종류별 성능평가를 진행하고, 입력된 이미지의 유형을 신경망을 통해 파악해 최적의 업 스케일링 기법을 사용하는 방법론에 대해 제시하고자 하였다.

제 2 장 업 스케일링 기법의 종류 및 특성

2.1 업 스케일링 이란?

업 스케일링 기술은 사진이나 동영상과 같이 픽셀로 이루어진 디지털 시각자료에서 픽셀과 픽셀 사이에 새로운 픽셀을 생성시키고, 생성된 픽셀을 기존의 픽셀 사이에 삽입해 해상도를 높이는 기술이다. 예를 들어, 256×256 픽셀, 즉 총 65,536 화소를 가진 사진을 1024×1024 픽셀, 1,048,576개의 화소를 가진 사진으로 변환한다 가정하자. 이때, 총 983,040개의 화소가 새로 형성되어야 하는데, 이때 이미지 업 스케일링은 다양한 수학적 기법들을 이용해 새로 형성될 화소들의 데이터 값을 계산, 예측하여, 기존의 픽셀에 추가하는 과정이다.

이미지 업 스케일링은 두가지 종류로 나눌 수 있는데, 크게 수학적 기법을 이용하는 경우와 AI 인공지능망을 이용하는 경우이다. 본 논문에서는 수학적 방식을 이용하는 업 스케일링 기법들에 대해 다룬다. 인공지능망을 활용한 기법을 사용하지 않는 이유는, 본 연구에서 이미지 종류를 네 가지로 분류하여 성능 평가를 진행하였는데, 이를 위해서는 타 이미지를 학습시킨 모델을 사용하는 인공지능 보간 기법보다는 순수 수학적 보간법만을 사용하는 것이 더 의미가 있다고 판단했기 때문이다.

2.2 Nearest Neighbor Interpolation 의 원리와 특성

Nearest Neighbor Interpolation, Proximal Interpolation, 또는 최근접 보간법은 가장 대표적인 이미지 업 스케일링 기법이다. 작동 방식이 다른 이미지 업 스케일링 기법들과 비교해 매우 단순하며, 이에 따라 높은 처리 성능을 보인다. 최근접 보간법은 한 픽셀의 값을 추측하기 위해서 X' 으로 정의된 픽셀의 데이터를 X' 과 가장 가까운 위치에 있는 픽셀 X 의 그래픽 데이터를 그대로 가져오는 방식으로 작동한다. $\omega(x) = \omega'(x)$ 과 같은 수학적 표기법으로 최근접 보간법을 나타낼 수 있으며,

이때 ω 를 픽셀의 데이터, x 는 데이터가 존재하는 픽셀, x' 을 보간하고자 하는 픽셀로 정의한다. 또한, 최근접 보간법의 원리는 보로노이 다이어그램 (Voronoi Diagram)으로 시각화 할 수 있다.




그림 1 20 개의 점에 대한 보로노이 다이어그램

[그림 1]의 보로노이 다이어그램에서, 임의의 위치에 배치되어 있는 20개의 점들을 둘러싸고 색에 따라 영역이 구분되어 있다. 해당 영역들은 20개의 점들 각각에 가장 가까운 영역을 표시한 것으로, 최근접 보간법 또한 동일한 원리가 적용된다. 점들을 정보가 있는 픽셀이라 한다면, 새로 삽입하고자 하는 정보가 없는 픽셀은 각 색깔 영역에 존재하게 된다. 따라서, 보간하고자 하는 픽셀은 자신의 위치로부터 가장 가까운 픽셀의 데이터를 그대로 가져오게 된다.




그림 2 최근접 보간법의 시각화

위의 그림 2로 알 수 있듯이, 최근접 보간법은 매우 단순한 원리로서 작동하며, 연산이 필요가 없어서 이에 따라 업 스케일링 과정에서 다른 보간법에 비해 매우 높은 성능을 보여준다. 단, 주변 픽셀의 값을 그대로 가져오기에, 픽셀들의 경계가 명확하게 보여지는 계단 현상(Aliasing) 이 일어난다. 이러한 최근접 보간법의 장점을 유지함과 동시에 단점을 보완하기 위해서는 계단 현상 방지 기술 (Anti-Aliasing) 이 사용되기도 한다. 계단 현상 방지 기술에 대해서는 본 논문의 후반부에서 집중적으로 다룬다.

2.3 Linear Interpolation 의 원리와 특성

Linear Interpolation, 또는 선형 보간법은 양 끝점의 값이 주어졌을 때, 그 사이의 보간하고자 하는




그림 3 선형 보간법을 통한 보간 과정

점의 값을 추정하기 위해 직선 거리에 따른 선형적 함수를 통해 그 값을 계산하는 보간법이다.




그림 4 선형 보간법의 시각화

Linear Interpolation, 또는 선형 보간법은 양 끝점의 값이 주어졌을 때, 그 사이의 보간하고자 하는 점의 값을 추정하기 위해 직선 거리에 따른 선형적 함수를 통해 그 값을 계산하는 방법이다. 위의 [그림 3]에서, 왼쪽 빨간 점을 $A(x_0, y_0)$, 오른쪽 빨간 점을 $B(x_1, y_1)$ 라 하면, 사이의 임의의 점 $C(x', y')$ 에 대해 선형 보간법을 사용한다 하자. 이때, $C(x', y')$ 에서 x' 과 y' 의 관계는

$\frac{y - y_0}{x - x_0} = \frac{y_1 - y_0}{x_1 - x_0}$ 의 식으로 정리된다. 이를 2D 평면에서 확장시키면 위의 [그림 4]처럼 최근접 보

간법보다 픽셀 간 차이가 부드럽게 나타난다.

2.4 Bicubic Interpolation 의 원리와 특성

Bicubic interpolation, 또는 쌍삼차보간법은 다항 보간법 중에서는 가장 성능이 뛰어나다고 평가받는 보간법이다. Bicubic interpolation 은 주변의 픽셀을 삼차식 형태로 보간한다. 따라서 주변 두 픽셀의 값을 바탕으로 $y = mx^3 + nx^2 + jx + k$ 의 m, n, j, k 값을 구하여 새로운 픽셀을 보간하는 방식이다.




그림 5 삼차 보간법




그림 6 삼차 보간법의 시각화

위의 [그림 5]에서 알 수 있듯이 삼차 보간법은 선형 보간법보다 인접 픽셀들 사이의 값 차이가 감소한다. 따라서 [그림 6]과 같이 샘플 데이터 보간이 훨씬 부드럽게 되어 성능도 좋게 나타난다.

2.5 Lanczos Interpolation 의 원리와 특성

Lanczos Interpolation 은 지금까지 소개했던 다항 보간법들과는 달리, 아래 그림 7의 함수인 Lanczos Kernel이라는 함수를 사용하여 보간을 하는 보간법이다.

$$L(x) = \begin{cases} \text{sinc}(\pi x) \text{sinc}(\pi x/a) & \text{if } -a < x < a, \\ 0 & \text{otherwise.} \end{cases}$$

그림 7 lanczos kernel

Lanczos interpolation 같은 경우에는 다항 보간법보다 훨씬 많은 양의 연산 처리가 요구되기 때문에 보간 성능이 현저히 떨어지는데, 크기가 큰 이미지에서는 이가 눈에 띄게 발생한다. 하지만 lanczos kernel의 특성에 의해 다른 보간법보다 더 부드럽게 이미지를 보간하는 특성이 있다.

제 3 장 이미지 업 스케일링 성능 평가 척도

3.1 이미지의 여러 가지 수치

2장의 이미지 업 스케일링 기법들이 적용된 이미지를 원본과 비교하기 위해서는 사람의 눈이 아닌, 이미지에 포함되는 픽셀 하나하나로 평가하는 객관적인 평가 척도가 필요하다. 현재 이에 맞는 다양한 정형화된 평가 척도가 존재한다.

이미지 품질 평가 척도는 크게 두 가지로 나눌 수 있다. 우선 원본 이미지를 축소시킨 다음 다시 업 스케일링 기법으로 확대시켜 원본 이미지와 차이를 비교하는 Full-Reference Quality Metrics 와, 비교 대상 원본 이미지 없이 인공지능을 활용하여 품질 평가를 하는 No-Reference Quality Metrics 가 있다. 본 논문에서는 Full-Reference Quality Metrics 만을 사용하여 이미지의 차이를 평가한다.

3.2 PSNR 수치의 특성과 계산법

PSNR은 Full-Reference Quality Metrics의 가장 대표적인 기법이다. PSNR은 Peak Signal-to-Noise Ratio의 줄임 말로, 원본과 업 스케일링 된 이미지와의 픽셀 값 차이의 평균값을 활용한다. PSNR의 수식은 $PSNR = \log_{10}(\frac{R^2}{MSE})$ 로 나타낼 수 있다. 이때 MSE 값은 mean-square-error로, 이미지에 해당하는 모든 픽셀을 원본과 비교하여 그 차이를 평균 낸 값이다. 따라서 MSE 수치가 작을수록 원본 이미지와의 차이도 적고, PSNR 수치는 때에 따라 99.999... 까지 커질 수 있게 된다. 하지만 원본 이미지와 업 스케일링 된 이미지와의 차이가 0이 되는 순간 (즉, 같은 이미지면) MSE가 0이 되어 PSNR 값을 정의할 수 없게 된다.

PSNR의 계산법에서 알 수 있듯이 PSNR은 픽셀의 값 하나하나를 수학적으로 계산하여 비교한 것으로 우리가 시각적으로 내린 평가와 크게 차이가 날 수 있다. 본 논문에서는 이를 보완하기 위하여 PSNR뿐만 아니라 다른 평가 척도를 도입하였다.

3.3 SSIM 수치의 특성과 계산법

SSIM도 PSNR과 마찬가지로 Full-Reference Quality Metrics 중 하나로, PSNR보다 좀 더 정교하고 사람의 시선과 비슷한 결과 수치를 내는 기법이다. Structural Similarity Index Map이라는 이름에서부터 알 수 있듯이, 수치적 차이만 비교하는 PSNR과 달리 구조적 유사성을 비교하는 척도이다. SSIM은 휘도, 대비, 구조 세가지를 사용하여 이미지를 평가한다. SSIM의 수식을 살펴보면

$$SSIM(x, y) = \frac{(2\mu_x\mu_y+c_1)(2\sigma_{xy}+c_2)}{(2\mu_x^2\mu_y^2+c_1)(2\sigma_x^2\sigma_y^2+c_2)}$$
이다. μ 는 평균, σ 는 분산으로 SSIM은 두 이미지의

구조적 유사 지수를 나타낸다. SSIM은 0과 100 사이의 값으로 나타나며, 그 수가 클수록 두 이미지간 유사도가 높다는 것을 의미한다.

이처럼 이미지의 전체적인 구조적 차이를 비교하는 평가수치인 만큼 사람의 시선과 PSNR보다 더욱 근접한 평가를 할 수 있기에 본 연구에서 각 이미지 종류별 보간법의 성능을 나타내는 수치로 SSIM을 채택하였다.

3.4 기타 수치들의 특성

Image quality metrics, 즉 이미지 품질 평가 척도에는 PSNR, SSIM을 포함하는 다양한 척도들이 존재한다. 이를 크게 두가지로 픽셀 기반 척도와 인공지능 기반 척도로 구분할 수 있다. 본 논문은 기본적인 보간법을 연구하였으므로 픽셀 기반 척도만을 사용하는 것이 적합하다고 판단하였다.

PSNR과 SSIM을 제외한 픽셀 기반 척도중에는 UQI, UQI-HVS 등 현재 잘 사용되지 않는 척도들과 EPIQA, SROCC 등 현재 개발과 연구가 활발하게 진행되고 있는 척도들도 존재한다. 이들은 현재 널리 사용되고 있는 픽셀 기반 척도인 PSNR, SSIM의 단점인 색감차이 구분, 인간의 시선에 맞지 않는 평가 결과 등을 개선하려는 노력을 하고 있다.

제 4 장 이미지 업 스케일링 성능 평가를 위한 실험 설정

4.1 실험의 변인 설정

본 연구는 다양한 크기와 화질의 이미지에 대하여 연구한 논문인 만큼 이미지의 통일성에 대한 변인 설정이 중요했다. 우선 이미지의 통일성과 관련해서 가장 중요한 수치는 바로 이미지에서 픽셀의 밀집도를 나타내는 수치인 dpi (dots per inch) 라고 생각했으므로 모든 이미지의 dpi를 최근 1920x1080 해상도의 모니터에서 가장 일반적으로 사용되는 96dpi로 통일하였다. 또한, RGB 컬러 체제에서 사용되는 3채널 24 비트 이미지만을 사용하고, JPG, JPEG 같은 손실 압축된 이미지가 아닌, 무손실 압축이 되는 PNG 포맷 만을 사용하여 압축과정차이로 인해 발생하는 손실률을 최소화했다. 또한 분석 이미지 데이터를 고화질, 저화질, 픽셀, 손상된 이미지 4가지로 분류했는데, 이를 위해 pytorch를 사용하여 이미지 종류 분류 신경망을 구축하고, 4가지 종류의 이미지 데이터를 kaggle의 데이터셋으로 각각 약 1000장씩 학습시켰고, 학습 시킨 모델을 사용하여 인풋 이미지의 종류를 4가지 중 하나로 분류하는데 약 81.2%의 정확도를 보였다. 이는 본 연구의 분석에 사용되었을 뿐만 아니라, 추후 확장되어 다른 연구에서 사용하거나 상품화 될 수 있다고 판단했다.

4.2 실험 방식 설정

모든 이미지의 원본을 17%로 축소시킨 후 다시 보간법을 사용하여 확대한 후 원본 이미지와 비교하는 방식으로 실험을 진행하였다. 또한 보간법의 성능을 평가하는 연구인만큼 이미지를 고화질, 저화질, 픽셀, 손상된 이미지 4종류로 나누어 각각의 이미지 데이터에 보간법을 적용하여 PSNR, SSIM 수치를 측정하였다. 측정한 값을 정리하여 각 보간법에 대한 측정 수치가 최댓값과 최솟값에 표시를 하여 결과를 더 직관적으로 나타내었다.

제 5 장 이미지 업 스케일링 성능 평가

5.1 성능 평가 데이터

이미지 데이터를 4종류로 분류해 각각 축소시킨 후 보간법 적용, 수치 측정을 하여 엑셀에 저장하는 프로그램을 개발하였다.

		damaged / damaged / damaged / damaged / damaged / 17								low_res / low_res / low_res / low_res / low_res /					
	INTERPOLATION METHODS	family.png	images.pr	kid.png	marry.png	som.png			INTERPOLATION METHODS	bear.png	camel.png	dog.png	green.png	man.png	
PSNR	Nearest Neighbor	19.3791	24.3568	25.1143	18.575	18.5332		PSNR	Nearest Neighbor	29.6839	27.3777	23.1998	34.3288	30.9144	
	Bilinear	21.2206	25.5533	26.7901	20.1974	20.0745			Bilinear	34.3237	31.982	26.0613	42.4171	36.7719	
	Bicubic	21.0002	25.2236	26.4587	19.9593	19.6507			Bicubic	36.3588	34.2678	26.1314	43.2438	39.2683	
	Lanczos	20.7854	25.0287	26.226	19.7459	19.4241			Lanczos	36.6976	34.6041	26.3982	43.3921	39.6896	
SSIM	Nearest Neighbor	0.55976	0.62934	0.8065	0.5108	0.5622		SSIM	Nearest Neighbor	0.79993	0.82747	0.69575	0.89467	0.84563	
	Bilinear	0.62439	0.67838	0.85591	0.57831	0.61339			Bilinear	0.91665	0.91683	0.80453	0.97755	0.94965	
	Bicubic	0.61521	0.67263	0.84841	0.56724	0.5991			Bicubic	0.93414	0.9326	0.80537	0.97809	0.96001	
	Lanczos	0.5933	0.66095	0.83517	0.54693	0.57696			Lanczos	0.93698	0.93405	0.81748	0.97888	0.96261	
		high_res / high_res / high_res / high_res / high_res / 17								pixel / 17 pixel / 17 pixel / 17 pixel / 17 pixel / 17					
	INTERPOLATION METHODS	bird.png	elephant.png	field.png	water.png	yoshi.png			INTERPOLATION METHODS	axolotl.png	Berry	Gan	breakfast	cliff.png	const.png
PSNR	Nearest Neighbor	30.341	20.3467	20.1837	23.0252	20.2807		PSNR	Nearest Neighbor	22.9386	16.4165	25.7779	30.46	19.9556	
	Bilinear	32.4222	21.719	21.5325	24.4537	22.6998			Bilinear	25.0699	18.0637	27.7248	32.3746	21.8922	
	Bicubic	32.4533	21.2795	21.3686	24.0476	22.5456			Bicubic	24.9655	17.8301	27.7059	32.2459	21.7477	
	Lanczos	32.29	21.0979	21.2174	23.7972	22.6008			Lanczos	24.8968	17.7282	27.6245	32.1505	21.5363	
SSIM	Nearest Neighbor	0.93489	0.48106	0.64668	0.61034	0.78903		SSIM	Nearest Neighbor	0.90664	0.63882	0.89279	0.91926	0.71549	
	Bilinear	0.95875	0.53283	0.69387	0.66735	0.84287			Bilinear	0.90372	0.63678	0.87836	0.89565	0.69268	
	Bicubic	0.96082	0.52179	0.68973	0.66344	0.83211			Bicubic	0.88308	0.62234	0.88519	0.91313	0.71065	
	Lanczos	0.95971	0.51055	0.68679	0.65098	0.81526			Lanczos	0.86544	0.62743	0.87078	0.90712	0.66579	

그림 7 성능 평가 데이터 일부 캡처

왼쪽 위 수치부터 시계방향으로 각각 손상된 이미지, 저화질 이미지, 픽셀 아트 이미지, 고화질 이미지 순서대로 나열 되어 있다.

5.2 결과 요인 분석

4가지 종류의 이미지 모두 조금씩 다른 결과가 나온 것을 볼 수 있다. 우선 손상된 이미지

데이터에서는 [그림 7] 뿐만 아니라 추가 데이터도 거의 100%로 PSNR 수치가 선형 보간법이 가장 높았고 최근접 보간법이 가장 낮았다. SSIM 수치도 거의 100%로 선형 보간법이 가장 높았고 최근접 보간법이 가장 낮았다. 고화질 이미지와 손상된 이미지에서 이와 같은 양상을 띄었다. 손상된 이미지를 보간할 때 최근접 보간법은 인접 픽셀 값을 그대로 사용하기 때문에 손상된 픽셀 값도 그대로 사용한다. 따라서 좋지 않은 수치가 나온 것으로 본 연구진들은 분석했다. 반면에 선형 보간법이 삼차 보간법보다 근소하게나마 더 좋은 성능을 보인 것에 대해서는 사진들이 모두 단색 배경을 가지고 있기에 더 많은 인접 픽셀을 기반으로 보간을 하는 삼차 보간법이 단색 배경까지 보간 연산에 포함시켜 좋지 못한 성능을 보였다고 분석했다. 픽셀 이미지에서 최근접 보간법이 가장 성능이 높게 나온 것에 대해서는 연구진들은 픽셀 이미지는 여러 개의 픽셀이 하나의 도트를 이루기 때문에 인접 픽셀의 값을 그대로 가져오는 최근접 보간법이 좋은 성능을 보였다고 분석했다. 마지막으로 저화질 이미지에 한해서만 lanczos interpolation이 더 좋은 성능을 보인 것은 이미지를 매우 부드럽게 보간하는 lanczos interpolation의 특성상 이러한 결과가 나타났다고 분석했다.

제 6 장 결론 및 고찰

앞서 서술한 연구 결과를 통해 본 연구에서는 각 이미지 특성 별 가장 효율적인 이미지 업 스케일링 기법이 무엇인지 알 수 있었다. 이 과정에서 각 기법들의 작동 원리와 특성, 그리고 각각의 기법들이 갖는 장단점에 대해 심층적으로 알아보았으며, 실험을 통해 얻은 결과를 설명할 수 있었다. 또한, 본 연구에서는 이미지 업 스케일링 과정에서 그 성능을 평가하기 위해 PSNR, SSIM 수치들을 도입했으며, 이 수치들이 어떤 특성을 갖는지, 어떻게 계산되는지, 그리고 본 연구의 실험 결과값을 설명하는 과정을 거쳤다. 이에 더해, 우리는 PyTorch를 이용한 딥러닝 이미지 종류 분류 모델을 제작하였으며, 이를 통해 일반 사진, 픽셀 아트, 손상 사진 (노이즈, 변색, 유실)을 높은 정확도로 구분할 수 있었다. 이 과정에서 분류된 사진을 각각의 업 스케일링 알고리즘을 통해 업 스케일링 시키며 의미있는 실험 결과를 얻어낼 수 있었으며, 본 연구에서 설계한 업 스케일링 방법이 한 가지의 알고리즘으로 모든 종류의 사진을 업 스케일링하는것 보다 크게 더 효율적이라는 결론에 이르렀다. 추후 후속 연구를 통해 보다 세부적인 구분 기준에 대해 이미지 업 스케일링 성능을 비교하고, 전통적인 다항 업 스케일링 기법들이 아닌 AI를 이용한 업 스케일링 알고리즘들에 대해서도 연구를 확장시킨다면 기존의 아쉬웠던 성능을 보여줬던 이미지 업 스케일러들에 대해 비약적인 성능 발전을 기대할 수 있을 것으로 보인다.

제 7 장 참고 문헌

1. 손주은, 이동건, 이승용, 이수영, 박정민, 방승범.(2022).모아레 영상 개선을 위한 대조 학습 네트워크.대한전자공학회 학술대회,(),1234-1236.
2. Dengwen, Zhou. "An edge-directed bicubic interpolation algorithm." *2010 3rd international congress on image and signal processing*. Vol. 3. IEEE, 2010.
3. Rukundo, Olivier, and Hanqiang Cao. "Nearest neighbor value interpolation." *arXiv preprint arXiv:1211.1768* (2012).
4. Hore, Alain, and Djemel Ziou. "Image quality metrics: PSNR vs. SSIM." *2010 20th international conference on pattern recognition*. IEEE, 2010.
5. Kirkland, Earl J. "Bilinear interpolation." *Advanced Computing in Electron Microscopy*. Springer, Boston, MA, 2010. 261-263.
6. Dumitrescu, Dragoş, and Costin-Anton Boiangiu. "A study of image upsampling and downsampling filters." *Computers* 8.2 (2019): 30.